

文章

早期检测的变换与深度学习算法 番茄叶病的检测与识别

穆罕默德·赛义德·扎赫拉尼^{ID}以及法瓦兹·瓦塞拉拉·阿尔萨阿德^{*}^{ID}

费萨尔国王大学计算机科学与信息技术学院

沙特阿拉伯Al-Ahsa P.O. Box 4000

* 通信: falsaade@kfu.edu.sa

摘要: 植物病害对粮食供应安全构成最大威胁, 而早期识别病害以减少经济损失是重大挑战。通过运用计算机视觉技术, 我们提出了一种前沿的人工智能解决方案, 用于番茄叶片病害分类。该网络模型展现出优异的识别效果, 同时采用迁移学习技术提升模型效率与成本效益。鉴于番茄病害可能严重影响产量与品质, 早期识别与诊断对成功防治至关重要。深度学习在植物病害识别领域展现出巨大潜力, 兼具高精度与高效能。本研究通过对比三种深度学习模型——DenseNet169、ResNet50V2及ViT变换模型——在番茄病害诊断中的表现, 将病害样本与健康样本均纳入训练测试数据集。DenseNet121模型表现最为出色, 训练准确率达到99.88%, 测试准确率更是高达99.00%, 整体准确率位居榜首。ResNet50V2和ViT模型也表现出色, 测试准确率分别达到95.60%和98.00%。我们的研究结果充分展现了深度学习在番茄病害精准高效检测方面的潜力, 这将有助于早期病害管理, 最终提升作物产量和品质。实验数据表明, 所提出的集成模型凭借极短的训练测试周期和卓越的分类性能脱颖而出。通过本研究, 专业人士将能够以简便快捷的方式实现植物病害的早期诊断, 从而有效预防新感染的出现。

关键词: 人工智能; 深度学习; 转化学习; 粮食安全; 植物病害



引用: Alzahrani, M.S.; Alsaade, F.W. 用于番茄叶病早期检测和识别的变换和深度学习算法。农学 2023, 13, 1184。

<https://doi.org/10.3390/agronomy13051184>

学术编辑: 路易斯·库阿迪奥与路易斯·曼努埃尔·纳瓦斯·格拉西亚

接收日期: 2023年3月7日

修订日期: 2023年4月14日

接受日期: 2023年4月18日

发布日期: 2023年4月22日



版权所有: ©2023年由作者。被许可方 MDPI, 瑞士巴塞尔。这篇文章是开放获取文章, 根据知识共享署名 (CC-BY) 许可的条款和条件分发 (<https://creativecommons.org/licenses/by/>)。4.0/。

1. 介绍

植物对人类生存至关重要, 因为它们为我们提供食物并保护我们免受辐射伤害。若没有植物, 地球上的生命将难以想象; 它们不仅为所有陆地生物提供食物, 还保护着阻挡有害紫外线的臭氧层。番茄作为全球种植的蔬菜, 因其营养丰富且安全可食用而备受青睐[1]。全球每年消耗的番茄量约达1.6亿吨[2]。许多人认为, 发展番茄产业能帮助农村社区获得急需的收入, 从而显著改善贫困状况[3]。番茄富含多种营养成分且全球广泛种植, 其种植与收获过程对农业经济具有重要影响。番茄具有药用特性, 能预防牙龈出血、高血压和肝炎等疾病[1], 其抗癌功效也得到充分证实。随着番茄日益受到欢迎, 市场需求持续增长。据统计, 近80%的农业产量[2]来自小农户。然而, 疾病和害虫导致约半数

这些农民每年的收成都至关重要。田间作物病害检测研究具有关键意义, 因为番茄所遭受的病虫害对其生长发育影响深远。根据联合国粮农组织企业统计数据库 (faostat) 2020年汇编的研究数据显示, 全球番茄产量达1868.21亿吨[1]。农业不仅是经济扩张的根本动力, 更是人类文明赖以建立的基石。农民需要防范的各类植物病害, 已成为农业生产面临的重要障碍。掌握植物病害防治方法并落实预防措施, 是优化作物产量的两大关键要素。若想在实现农业高产的同时节约资金、减少损失, 及时发现病害至关重要。如今所有流程都由计算机系统自动化处理, 使得防控措施的实施变得轻松便捷。一方面, 在合理时间内准确诊断和分类疾病对于保持番茄的质量和数量都至关重要。

环境条件可能在多种植物病害的发展中起作用。病害三角是一种概念模型, 代表了三个关键因素之间的关系: 环境、宿主和病原体。病害三角的建立是为了解释病害如何传播。这种模型创建于20世纪50年代, 自问世以来一直被广泛使用。由此可见, 病害不可能发生, 因为如果三角中的任何一个条件缺失, 病害就无法发生。许多非生物因素, 包括空气流动、温度、湿度、pH和浇水, 都可能对植物产生显著影响。真菌、细菌和病毒是一些可能攻击植物的生物体。病原体是导致植物患病的生物体。术语“宿主”指的是被病害感染的植物。疾病的发生是所有风险因素同时汇聚的结果[3]。一般来说, 感染的特征是通过植物内部逐渐显现的症状, 因此, 一旦感染了植物, 大多数疾病都会迅速传播。

病原真菌、细菌和病毒, 以及恶劣的气候条件, 是植物病害的诸多潜在致病因素之一。由于这些病害的存在, 植物的基本功能 (如光合作用、授粉、受精和萌发) 可能受到干扰。这凸显了在当前医学技术允许的范围内尽早准确诊断病害的迫切需求。

技术发展已达到可通过工具诊断植物是否患病、若患病则可确定其具体病种的程度, 而不再仅依赖人类专家的判断。随着技术设备获取照片质量的持续提升, 诸如物体识别与分类、图像处理及人工智能算法等程序的检测结果正变得日益精准。机器学习 (ML) 与深度学习 (DL) 已证明比传统优化和预测方法更为高效。首先, 与需要人工提取特征且受数据量限制的传统技术不同, 新型系统能够自动从海量数据中学习。其次, 机器学习和深度学习模型对未见过的数据具有良好的泛化能力, 这比以往方法有了显著提升。与传统方法相比, 机器学习和深度学习模型能捕捉数据中非线性且复杂的关联。因此, 机器学习在处理多变量动态场景 (尤其是存在复杂交互关系的场景) 时表现出色。如今, 人工智能 (AI) 已广泛应用于通信、建筑、磁学、物理和生物学等多个领域[4-8]。在这一领域, 精准识别植物病害并及时分类至关重要[9]。如今人工智能已发展到能直接从原始图像中自动识别植物病害的程度[10, 11]。

迄今为止, 已有大量研究致力于确定植物病害的致病原因。大多数研究利用现有的数据集、模型和文库进行实验。

为实现植物叶片病害识别与分类的自动化, Singh和Misra[12]开发了一种基于图像分割技术的算法。通过运用遗传算法, 他们在识别五种不同病害时取得了97.60%的总体准确率。Zhang等人[13] 研究人员通过分析黄瓜叶片样本数据库进行病害识别。本研究采用k均值聚类算法对病叶进行分割, 提取其形状与颜色特征用于病害诊断。运用稀疏表示方法对受损叶片进行分类时, 准确率达到86.00%。作为人工智能技术的卷积神经网络(CNN)模型可应用于植物病害检测与诊断[14]。模型训练使用包含87,848张图像的数据集, 该数据集涵盖58种独特的植物-病害组合, 涉及25个不同植物物种, 最终计算出99.53%的识别成功率。

近年来, 图像处理[15, 16]、模式识别[17, 18]和计算机视觉[19, 20]在农业领域的应用突飞猛进, 尤其在自动化病虫害检测方面成效显著。传统计算机视觉模型在预处理和构建图像特征时往往面临复杂性和耗时的问题, 这些任务常引发技术瓶颈。特征提取的精准度和学习算法的构建质量, 直接决定着系统检测效果[21-23]。得益于算力提升、存储容量扩张和海量数据的加持, 深度学习在病害检测领域正大放异彩。该技术最近成功应用于植物病害检测这一长期难解的难题。作为机器学习的分支, 深度学习这个术语本身具有特定的学术内涵。卷积神经网络(CNN)是深度学习领域应用最广泛的算法之一, 广泛应用于图像分类、物体识别和语义分割等任务[24, 25]。这类网络能有效捕捉图像、物体及场景中的规律特征, 其核心优势在于通过图像数据自主学习分类, 从而省去了人工费力提取目标特征的繁琐过程[26, 27]。

本文将系统评估并解析当前主流的深度学习方法。尽管已有大量研究探讨番茄作物病害检测技术, 但现有模型仍存在改进空间。为此, 我们开发了一种包含两层卷积网络、两层最大池化层的卷积神经网络模型, 通过分析隐藏层数据实现番茄植株病害识别, 并配备专门的病害预警模块。该方案使农户无需依赖农业专家指导即可自主解决问题, 其核心在于精准识别可能危害作物的各类病害。本模型旨在辅助植物疾病的早期诊断, 从而提高农业活动的整体生产力, 进而增加粮食供应。

开发自动化技术以诊断可能影响番茄植株的疾病是本项目的核心驱动力。以下为本研究的部分贡献, 旨在填补现有研究中的若干空白:

- 通过评估作物的产量、生产能力、籽粒品质及养分保持能力等多种特性, 可实现对植物病害的精准诊断。
- 就构建新型CNN模型及利用所提出的CNN创建新集成结构提供指导建议。
- 采用先进的变换学习方法检测番茄叶部病害对于保障粮食安全至关重要。
- 与该领域早期发表于学术期刊的研究相比, 本研究提出的模型准确率百分比有所提升。
- 提高分类可靠性并减少培训与考核所需时间。

本文提出了一种基于三种不同深度学习模型(DenseNet169、ResNet50V2和transform ViT模型)及数据增强技术的番茄叶片早期病害识别与分类架构。该架构旨在准确预测

针对可能影响番茄叶片的各类病害, 本研究旨在建立一个可靠的框架, 用于通过番茄叶片照片筛查病害指标。

2. 研究背景

来自不同机构的研究人员利用前沿技术, 如机器学习和神经网络设计(例如Inception V3网、VGG 16网和Squeeze Net), 开发了自动疾病检测系统。他们采用高度精确的方法来诊断番茄叶片组织中的植物疾病。

为实现番茄病害的检测与分类, 预训练网络模型的准确率可达94.00%至95.00%[28, 29]。通过使用包含300张图像的数据集及树分类模型与分割技术, 研究人员成功识别并分类出六种番茄叶部病害[30]。另有研究提出[31], 采用特定方法可实现93.75%准确率的叶片病害分类。通过图像处理软件与分类方案的配合使用, 植物叶部病害有望实现精准识别与分类[32]。使用了一部配备800万像素摄像头的智能手机拍摄了多种状况的照片, 然后将所得数据分为两组: 健康和患病。图像处理过程包括三个不同的步骤: 增强对比度、图像分割和特征定位。采用了一个多层人工神经网络和前馈神经网络来进行分类任务, 并比较了这些网络的结果。与多层感知机(MLP)网络和径向基函数(RBF)网络的结果相比, 它们的表现要好得多。在研究过程中, 植物叶片的图像被分解为健康和患病部分。然而, 这并不能确定问题的具体原因。为了诊断叶片疾病, 研究人员使用了颜色空间分析、颜色时间、直方图和颜色一致性作为分类器, 准确率达到87.2%。

研究人员使用了AlexNet和VGG 19模型, 以13,262帧的图像尺寸检测损害番茄收成的疾病。该模型的准确率达到97.49%[33]。为了获得95%的准确率。针对无法检测危害乳用作物病毒[34]的问题, 我们采用迁移学习和卷积神经网络(CNN)模型。为实现番茄植株叶片表面病害的识别与分类, 基于AlexNet的深度学习机制通过神经网络训练的迁移学习方法, 最终达到95.75%的准确率[35, 36]。为识别可能危害番茄叶片的1000种独特病害, 我们构建了ResNet-50模型, 通过展示3000张标注有病害名称(如斑点枯萎病、晚疫病、黄化卷叶病等)的图像进行训练。该模型将第一卷积层的核尺寸调整为 11×11 , 并将网络激活函数改为LeakyReLU。经过多次迭代优化后, 其病害分类准确率提升至98.30%, 精确率达到98.00%[37]。针对番茄叶片病害检测与分类, 研究者还提出了简化版八层CNN模型[38]。本研究使用了PlantVillage数据集[39], 该数据集包含多种农产品的综合数据。通过将深度学习应用于番茄叶片数据集, 作者专注于疾病诊断以提升性能。

近年来, 卷积神经网络(CNN)已成为植物病害诊断的可靠工具[40, 41]。部分研究[42, 43]聚焦于通过消除光照不均和高风险场景中背景同质性带来的干扰来提升特征检测质量。另一些研究则致力于通过检测复杂环境来实现特征检测的改进。目前仅有少数学者开发了实时模型以加速植物病害检测[44, 45]。另有学者通过模型开发实现了植物病害的早期识别[46, 47]。如参考文献中所述。[48]作者通过分析番茄叶片的数码照片来检测多种病害的存在。该研究采用基于卷积神经网络(CNN)和人工智能算法的分类模型, 其识别准确率达到96.55%, 可有效区分不同病害。多项研究中, 深度神经网络模型已被用于番茄叶片的疾病识别。参见文献。[49]例如, 作者比较了四种替代模型(LeNet、VGG16、ResNet和Xception), 并得出结论认为VGG16模型

当用于分类九种不同疾病时, 该模型可实现最佳性能(准确率99.25%)。其他研究已对深度神经网络模型在番茄叶片疾病诊断中的有效性进行了探讨。根据参考文献[50]使用AlexNet、GoogleNet和LeNet模型时, 相同问题的解决准确率达到95.00%或更高。Agarwal等人[51]构建CNN架构, 并将其与其他机器学习模型(如随机森林和决策树)及深度学习模型(用于将数据分类为10组, 包括VGG16、Inception-v3和MobileNet)进行比较。结果表明准确率提升了99.20%。

众多研究致力于通过融合随机森林、支持向量机和多项逻辑回归等分类网络模型, 提升分类准确率——这些模型仅是基于叶片特征构建的分类网络的典型代表[52]。借助MobileNetv2和NASNetMobile网络架构, 我们成功实现了叶片特征的有效提取。研究人员已经证明, 通过结合这两种技术, 类别识别的准确性可以大大提高。许多研究已经成功地使用诸如Mask R-CNN等算法诊断植物疾病[53]。通过使用几种技术, 即K近邻和Gabor滤波器以及K近邻(KNN), 计算成本和模型大小已经减少。这两种方法都被用来尝试减少深度学习计算所需的时间和资源。为了降低计算成本, 参考文献的作者们提出了以下方法。[54]采用仅含33个滤波器的SqueezeNet架构。YOLO-Tomato基于YOLOv3开发, 被文献[55]的作者所采用。[57]为提升番茄识别性能, YOLOv3被提出作为解决这些问题的方案。该模型采用厚架构设计, 既便于特征复用, 又能助力构建更精准且更紧凑的模型。

3. 材料与方法

由于番茄叶片结构复杂且受多种病害影响, 其病害识别过程可能较为困难。近年来, 深度学习技术在番茄病害计算机辅助检测领域崭露头角。该技术通过深度神经网络, 能够从海量图像数据中学习复杂模式。推荐的深度学习番茄病害检测方案包含几个关键步骤: 首先收集番茄叶片图像数据集, 包含健康叶片与病害叶片的样本; 经过预处理后, 利用这些图像训练卷积神经网络(CNN)等深度神经网络识别图像中的复杂特征; 模型训练完成后, 可将新获取的图像归类为健康叶片或病害叶片。通过调整模型参数和新增数据, 可进一步提升模型性能与识别精度。最终, 可通过测试集图像验证模型的准确性和泛化能力。图1展示了所建议的番茄植株叶片病害分类与检测系统的基本架构。

3.1. 数据集

本研究采用的番茄叶病数据集包含11,000张受10种不同病害影响的番茄叶片图像。每个病害类别(包括番茄花叶病毒、靶斑病、细菌性斑点病、番茄黄化卷叶病毒、晚疫病、叶霉病、早疫病、红蜘蛛(双斑红蜘蛛)、健康番茄和霜霉病)均包含1100张图像。该数据集可在Kaggle平台公开获取。表1展示了番茄叶片特征参数及各病害类别样本数量, 图2则展示了番茄叶病的典型样本。数据集可通过以下链接获取<https://www.kaggle.com/datasets/kaustubhb999/tomatoleaf>(访问日期: 2023年1月20日)。

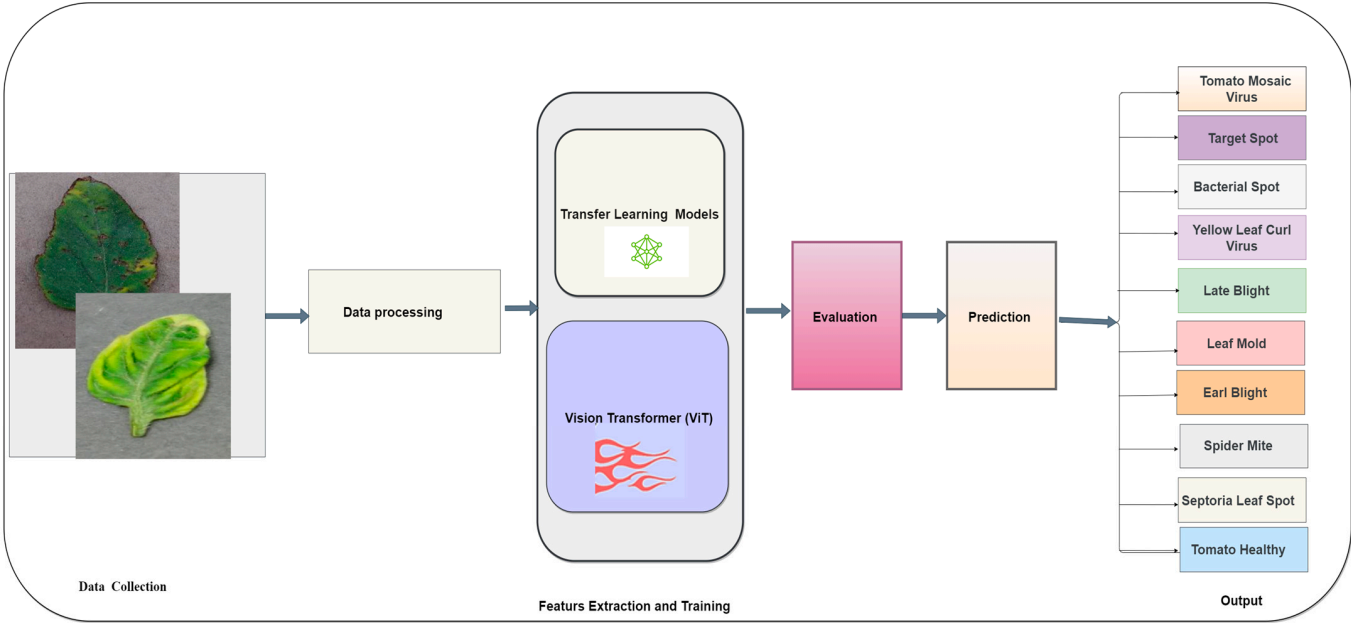


图1.建议方法的结构。

表1.柑橘叶特征。

课	样本数	描述
花叶病毒	1100	这是一种可对番茄植株造成显著损害的病毒性病害，会导致植株生长迟缓和产量下降。症状包括叶片上出现明暗相间的花叶状斑驳、生长发育不良以及果实畸形。该病害通过接触受感染的植物材料传播，可通过使用抗病番茄品种及卫生管理等栽培措施进行防控。
靶点	1100	这种病是由灰霉菌引起的，会导致叶片和茎干上出现圆形、凹陷的同心圆环状病斑。它会导致落叶和减产，但可以通过杀菌剂和轮作、卫生等栽培措施来控制。
细菌斑	1100	这是一种常见病害，可对番茄植株造成严重损害，导致产量下降和果实品质不良。症状包括叶片和果实上出现褐色、凹陷的病斑，最终会变成黑色并结痂。这种病是由菜青虫黄单胞菌腹水引起的，可以使用含铜杀菌剂和轮作、卫生等栽培措施来控制。
黄叶卷曲病毒	1100	这是一种病毒性疾病，会对番茄植株造成严重损害，导致生长迟缓和果实产量下降。症状包括叶片发黄卷曲以及果实畸形。该病由白飞虱（Bemisia tabaci）传播，可通过杀虫剂、抗病番茄品种以及轮作和卫生等栽培措施进行防治。
晚疫病	1100	这种病害由病害疫霉菌引起，会迅速对番茄植株造成毁灭性破坏。症状表现为叶片和茎秆上出现水渍状病斑，随后迅速变褐并坏死。可通过使用杀菌剂和采取轮作、卫生管理及清除受感染植株等栽培措施来控制该病害。
叶模	1100	这种病害是由Passalorafulva真菌引起的，会对番茄叶片造成严重损害，降低植株生长和产量。症状包括植株下部叶片发黄和褐色病斑。可以使用杀菌剂和栽培措施来控制这种病害，例如轮作和卫生。

表1.续.

课	样本数	描述
早疫病	1100	这种病害是由紫菜枯萎病菌引起的，其特征是在植物的下部叶片上出现深棕色的同心圆斑点。它会导致落叶和减产，但可以通过杀菌剂和耕作方法来控制，比如轮作和修剪。
蜘蛛螨	1100	这些微小的蛛形纲昆虫会啃食番茄叶片背面，导致植株黄化和生长迟缓，造成严重危害。可通过捕食性螨虫、杀虫皂及轮作、卫生等栽培措施进行防治。
番茄健康	1100	该类别包含健康番茄叶片的图像，可作为与病害叶片进行对比的参考。
七叶树斑点病	1100	该病由真菌西红柿霜霉病引起，其特征是植株下部叶片上出现中心深棕色、边缘黄色的小圆形病斑。它可导致显著的落叶和产量损失，但可通过使用杀菌剂和栽培措施（如轮作和卫生管理）进行控制。




图2.展示的数据集样本。

3.2. 数据预处理

数据预处理步骤至关重要，因为它能同时提升图像分类过程中所用分类方法的数据质量与整体性能。数据预处理的主要目标是通过消除可能影响模型准确性的差异值、噪声或异常值，为深度学习模型准备图像。具体而言，通过优化数据结构使其更易于模型分析来实现这一目标。在图像分类的深度学习模型中，通常会采用图像缩放和标准化等常见预处理方法。

图像重置是指通过调整图片尺寸,使其符合模型训练的标准尺寸。这能有效降低模型复杂度,并确保模型在统一尺寸的图像上进行训练。图像标准化则涉及调节每张图片的亮度和对比度,使其在所有图片中保持一致。此举旨在确保模型训练所用照片具有可比性。应用数据预处理技术可生成更统一、高质量的数据集,从而提升模型的准确率。这些技术可通过PIL、OpenCV等图像处理库实现。

3.3. 迁移学习算法

迁移学习方法允许模型在某一任务上进行训练后,再应用于不同但相关的任务。当特定任务缺乏标注数据或任务与已解决任务相似时,这种方法尤为实用。通过利用预训练模型所学的知识 and 特征,可节省大量时间和资源。此外,迁移学习能有效提升模型性能,既能降低过拟合风险,又能增强模型对新数据集的泛化能力。在决定采用迁移学习前,需综合考量两个关键因素:新任务可用的标注数据量,以及预训练模型与新任务的相似程度。若新任务与预训练模型的原始任务差异显著,或存在海量标注数据时,建议直接从头开始重新训练模型。通过迁移学习不仅能提升模型性能,还能减少标注数据的依赖。该技术适用于多种模型(包括卷积神经网络),既可通过特征提取方法实现,也可采用微调策略来完成。

3.3.1. DenseNet121模型

DenseNet121是黄等人于2017年作为DenseNet系列架构之一提出的流行卷积神经网络(CNN)模型。该网络基于层间密集连接的概念,这种设计能更高效地促进信息在网络中的流动,从而提升其准确率。DenseNet121架构由多个密集块组成,每个密集块包含一组卷积层,这些卷积层与所有后续层[58–61]保持密集连接。

本研究采用预训练的DenseNet121模型进行番茄病害识别。按照常规做法,我们运用迁移学习技术,利用ImageNet海量数据集训练得到的权重对预训练模型进行初始化。在移除并替换预训练模型顶层后,新增了包含全局平均池化层、两个全连接层(含512和256个神经元)以及两个批归一化层的网络结构。当第二层完全连接后,我们在激活层新增了ReLU激活函数。最终输出层配置了10个神经元,对应10种不同番茄病害类型,如图3所示。

选择该架构是因为DenseNet模型在各类图像分类任务中表现优异,且其紧凑的结构特别适合迁移学习。通过引入全局平均池化层来减少模型参数量,并添加批量归一化层以提升训练过程的稳定性和收敛速度。DenseNet121模型的关键参数详见表2。

表2.详细说明DenseNet121模型参数。

DenseNet121参数	值
批量大小	8
优化器	SGD
学习率	0.0001
动量	0.9
早期终止（es）	是
模型检查点	是
轮数	100




图3.稀疏网络121模型在番茄病害检测中的应用。

3.3.2. ResNet50V2模型

ResNet50V2是一种卷积神经网络架构，常用于计算机视觉领域的图像分析与分类任务，包括植物病害识别。该预训练模型采用从大型图像处理数据集中学习的权重进行初始化，这在迁移学习中是常规做法。我们移除了预训练模型的顶层网络，并替换为一组新设计的层。在预训练的ResNet50V2模型基础上新增的分类器，专门用于使网络适应新的图像分类任务。预训练模型的输出会经过全局平均池化2D层处理，该层通过沿高度和宽度轴取平均值的方式，降低特征图的空间维度。由此生成的固定长度特征向量可编码输入图像的关键特征。

特征向量经过两个全连接层处理，这两个层分别包含512和256个神经元，它们学习将特征向量映射到能捕捉新图像分类任务判别信息的高层次表征。每个全连接层后都添加了批归一化层，以稳定训练过程并加速收敛。在第二个全连接层之后，通过引入使用ReLU激活函数的激活层，网络中加入了非线性特征。这种设计使网络能够获取更细腻的代表信息。

最终，第二层全连接层的输出将输入到一个包含10个神经元的全连接层，该层采用softmax激活函数，输出数据集中10个类别的概率分布。该层通过学习将高层次表征映射至网络的最终输出，即预测的类别标签。

输入图像。图4展示了用于检测番茄病害的ResNet50V2模型结构，表3列出了该模型的参数配置。



图4.稀疏网络121模型用于番茄病害检测。

表3.描述ResNet50V2模型参数。

参数	对价值的看法
#优化器	SGD
#学习率（lr）	0.0001
#动量	0.9
#早期终止（es）	是
#模型检查点（mc）	是
#周期数	100

3.3.3. 视觉变换器

视觉变换器（ViT）是一种新型的图像分类架构，在深度学习领域备受关注。与传统的卷积神经网络（CNN）不同，ViT采用基于变换器的架构，该架构在自然语言处理任务中已取得显著成功。

ViT架构包含若干核心组件。首先，输入图像被分割为一系列固定尺寸的图像块。随后，每个图像块被展平为一维向量，并通过嵌入层进行映射，从而将图像块转换至更高维度的特征空间。随后将这些补丁嵌入输入到Transformer编码器中，该编码器通过一系列自注意力机制来学习补丁之间的上下文关系，如图5所示。

我们采用的训练流程分为以下步骤：首先将输入图像通过“图像分割”层，该层将图像分割成6×6的非重叠网格。这会将二维图像转换为三维张量，其结构由三个维度构成——批次大小、图像分割尺寸×分割尺寸×通道数，以及颜色通道数（RGB图像通常为3个）。随后，分割后的张量进入“图像编码器”层，该层通过全连接层应用线性变换，并为每个分割块添加可学习的位置嵌入。这一过程能帮助模型捕捉图像块间的空间关系，使其准确识别图像中各分割块的相对位置。



图5.变形器编码器后的图像。

该层负责生成模型对每张输入图像的预测结果。训练过程中采用AdamW优化器对模型进行优化，该优化器是Adam优化器的改进版本，加入了权重衰减正则化机制。所使用的损失函数为稀疏分类交叉熵，这是多类别分类问题的常用选择。图6展示了用于番茄病害检测的ViT变换模型结构，其关键参数详见表4。




图6.植物信息小车（ViT）模型在番茄病害检测中的应用。

表4.描述ViT模型参数。

参数	值
学习速率	0.001
重量衰减	0.0001
批量大小	128
数个时期	50
图像大小	72
补丁大小	6
贴片数量	144
投影维数	64
头数	4
变压器单元	(128, 64)

4. 实验

本研究评估了DenseNet121、ResNet50V2和ViT这三种深度学习分类算法在番茄病害诊断中的有效性。实验采用包含健康与病害番茄照片的数据集进行模型训练、测试和验证。训练配置为配备第八代酷睿i7处理器、NVIDIA GeForce 1070显卡及8GB内存的笔记本电脑，使用TensorFlow和Transformer架构库开发模型。训练集与测试集均基于本研究数据集生成，随后进行对比分析。本研究旨在验证所开发的深度学习模型能否准确分类新拍摄的番茄照片。为此，数据集中的每个类别均被划分为1000张用于训练的照片和100张用于测试的照片。这种划分的主要目的是为深度学习模型提供多样化的照片集，使其能够从中学习，最终目的是评估模型将发现的规律推广到未见过图像的能力。

4.1. 绩效测量

为评估深度学习模型的成效，通常会以金标准作为准确率的衡量基准。该指标通过将准确预测数量除以总预测数量来计算，用以衡量模型的预测效能。

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{FP} + \text{FN} + \text{TP} + \text{TN}} \times 100\%$$

(1)

在深度学习模型评估中，精确度是衡量其性能的标准指标，尤其适用于分类任务。该指标通过将正确预测数量除以总预测数量，来评估模型正向预测的可靠性，其计算公式如公式(2)所示。

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \times 100 \%$$

(2)

深度学习模型广泛使用一种称为召回率的评估统计量，尤其在处理分类问题时。该指标以数值形式呈现数据集中与模型生成的准确阳性预测相对应的阳性实例比例。通俗来说，即通过计算真阳性预测数量占数据集阳性案例总数的比例来实现。

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \times 100$$

(3)

F1分数是深度学习模型中常用的评估指标，尤其适用于分类问题。该指标通过平衡精确率与召回率之间的权衡关系来实现性能优化。

通过计算两个指标的调和平均值，该指标在处理不平衡数据集或识别稀有类别时具有实用价值。

$$F1 - score = 2 \times \frac{precision \times Sensitivity}{precision + Sensitivity} \times 100$$

(4)

在哪里

FP: 假阳性

TP: 真阳性

FN: 假阴性

TN: 真阴性。

4.2. 结果

4.2.1. DenseNet121模型结果

表5显示DenseNet121模型在90%训练集和10%测试集上表现优异。该模型采用八批次大小和随机梯度下降（SGD）优化器进行100轮训练。为防止过拟合并缩短训练时间，采用了提前终止法，在34轮训练后结束训练。DenseNet121在训练阶段准确率达到99.88%，而测试准确度为0.99%。表S1展示了该模型在90%训练集和10%测试集上的结果，可见其准确率高达98%。

表5.DenseNet121模型结果（90%训练和10%测试）。

班级名称	精密度%	回忆率	F1-Score%	支持
细菌性斑点	96	100	98	100
早疫病	99	100	00	100
晚疫病	100	100	100	100
叶霉病	100	100	100	100
七叶斑	97	100	99	100
Spider_Mites_Two-Spotted_Spider_Mite	99	99	99	100
靶点	100	93	96	100
黄叶卷曲病毒	100	98	99	100
花叶病毒	99	100	100	100
健康	00	100	100	100
DenseNet121的准确性			99	1000
DenseNet121_Macro Avg	99	99	99	1000
DenseNet121_Weighted Avg	99	99	99	1000

图7展示了DenseNet121模型在90%训练集和10%验证集上的表现，该模型旨在识别和分类可能影响番茄叶片组织的疾病。根据图示，训练集准确率从72.00%开始逐步提升至99.98%。验证集准确率从86.00%起步，最终达到99.00%。DenseNet121模型在验证集上的准确率损失为0.2。图S1展示了采用80%训练集和20%验证集的DenseNet121模型性能，其中训练集准确率最高达到98.45%，验证集损失从0.8降至0.1。

如图8和图S2所示，所提出的Dense-Net121模型及其评估结果生成了混淆矩阵。评估参数设置为（90%作为训练集，80%作为测试集；10%作为训练集，20%作为测试集）。该混淆矩阵展示了各分类中收集的真阳性率（tTP）、真阴性率（TN）、假阳性率（FP）及假阴性率（FN）数值。基于多图形处理单元（MGPU）架构，目标点类具有较高的环境误分类率。在叶片病害分类方面，建议模型在90%训练和10%测试的情况下达到了99.64%的验证准确率，而密集网络121模型在80%训练和20%测试的情况下达到了98.45%的准确率。




图7.DenseNet121 模型的性能；（a）DenseNet121 模型的准确度和（b）DenseNet121 模型的损失（90%的训练和10%的测试）。




图8.DenseNet121的混淆矩阵（90%训练和10%测试）。

4.2.2. ResNet50V2模型结果

ResNet50V2模型在90%训练集和10%测试集上的表现如表6所示。该模型采用八批次训练数据，使用随机梯度下降（SGD）优化器训练100个周期。为防止过拟合并缩短训练时间，我们采用了提前停止法，在训练20个周期后终止训练。最终模型在训练集上达到99.49%的准确率，在测试集上达到95.60%的准确率。

表S2展示了采用80%训练集和20%测试集的ResNet50V2模型；该模型成功达到了94.31%的准确率。

表6.ResNet50V2模型结果（90%训练和10%测试）。

班级名称	精密度 (%)	回忆率 (%)	F1评分 (%)	支持
细菌性斑点	99	100	100	100
早疫病	97	93	95	100
晚疫病	88	100	93	100
叶霉病	96	95	95	100
七叶斑	96	96	96	100
Spider_Mites_Two-Spotted_Spider_Mite	96	90	93	100
靶点	98	87	92	100
黄叶卷曲病毒	100	98	99	100
花叶病毒	89	100	94	100
健康	00	97	98	100
精度			96	1000
DenseNet121_Macro Avg	0.96	96	96	1000
DenseNet121_Weighted Avg	0.96	96	96	1000

图9展示了ResNet50V2模型在番茄叶片病害识别中的表现。该模型通过将数据集划分为90%的训练集和10%的测试集进行验证，其验证准确率达到96.00%。训练阶段，模型准确率从初始的78.00%逐步提升至最高99.49%。在验证过程中，ResNet50V2模型的准确率损失值始终低于0.1。




图9.ResNet50V2模型的性能；（a）ResNet50V2模型的准确率和（b）ResNet50V21模式损失（90%训练集与10%测试集）。

图S3展示了ResNet50V2模型在80%训练集和20%测试集上检测番茄叶片病害的效能。该模型在验证测试中的准确率达到94.30%。在验证过程的这一阶段，ResNet50V2模型的准确率损失值低于0.2。

图10和图S4展示了ResNet50V2模型的混淆矩阵，该矩阵通过将数据集分为90%（80%）用于训练、10%（20%）用于测试生成。该矩阵表明该模型对番茄病害检测具有显著的正向影响，但每1000个样本中仍有42个被错误分类。如结果所示，建议的ResNet50V2模型使用训练数据集对测试类别预测的准确率达到99.49%。

在混淆矩阵中，90%作为训练集，10%作为测试集时，ResNet50V2模型在80%训练集和20%测试集下的错误分类为54个简单类别。




图10.ResNet50V2模型的混淆矩阵（90%训练和10%测试）。

这一结论的成立源于实验结果表明该模型能够准确预测类别。通过分析实验数据，我们可自行验证这一观察结果。DenseNet121生成的混淆矩阵显示，该模型对番茄病害检测具有显著的正向影响，在1000个样本中仅有10个样本被错误分类。

4.2.3. VIT模型结果

表7显示了VIT模型在实验数据集中9%训练集和210%测试集上各分类的分类性能结果。基于此，我们能够推断出所建议模型的性能，该模型具有将疾病分类准确率超过98.00%的能力。根据表格所示数据可见，数据集中每个指定类别的召回率指标值均较高。VIT模型采用八种批量大小和SGD优化器进行训练，经过100个训练周期后，模型在训练集和测试集上均达到98.00%的准确率。将数据集按80%训练集和20%测试集划分后，VIT模型的测试结果如表S3所示。

表7.ViT模型结果（90%训练和10%测试）。

班级名称	精密度 (%)	回忆率 (%)	F1评分 (%)	支持
细菌性斑点	99	94	96	100
早疫病	97	99	98	100
晚疫病	98	100	99	100
叶霉病	99	96	97	100
七叶斑	99	99	99	100
Spider_Mites_Two-Spotted_Spider_Mite	00	98	99	100
靶点	95	99	97	100
黄叶卷曲病毒	98	97	97	100
花叶病毒	100	100	100	100
健康				
精度	95	98	97	100
DenseNet121_Macro Avg			98	1000
DenseNet121_Weighted Avg	98	98	98	1000
细菌性斑点	98	98	98	1000

图11 1展示了通过将数据集划分为90%训练集和10%测试集后，训练准确率与验证准确率的对比结果。图11 a表明，当将训练轮数设置为100轮且保持学习率0.0001时，可获得98.00%的准确率。图11 b则对比了验证集与训练集的损失值。根据本研究方法论，可以合理推测增加迭代次数将提升数据准确率。反之，若延长训练阶段时长，总训练轮数也会相应增加。图S5展示了采用80%训练集和20%测试集时ViT模型的准确率与损失性能表现。




图11。ViT模型性能；（a）ViT模型准确率和（b）ViT模型损失（90%训练和10%测试）。

如图12所示，混淆矩阵的建立旨在直观呈现ViT模型对番茄叶片数据集的分类效果，具体表现为在验证集和训练集中，模型在特定迭代次数内正确分类的图像数量。根据ViT模型的混淆矩阵显示，该模型对番茄病害检测具有显著优势，1000个样本中仅有20个被错误分类。图S6展示了ViT模型在80%训练集和20%测试集上的混淆矩阵分布。




图12.ViT模型的混淆矩阵（90%训练和10%测试）。

5. 讨论

番茄是全球最重要的农作物之一，具有较高的经济价值和营养价值。然而，番茄常受多种病害影响，这些病害会降低产量和品质。对番茄病害进行早期检测和准确诊断，对于有效管理与预防病害至关重要。

本研究进一步证实了所提出番茄病害检测方法的有效性，并为不同模型的性能提供了有价值的见解。研究结果表明，开发能够早期检测和管理番茄植株病害的自动化系统具有显著的准确性，最终可提高番茄生产的效率和可持续性。

为诊断番茄叶片病害，本研究采用ImageNet数据集预训练的多种卷积神经网络（CNN）模型，并将其与该数据集进行对比。通过迁移学习方法，训练了三种替代CNN模型——DenseNet121、ResNet50V2和ViT。所有模型均使用包含病害与健康样本的番茄病害图像集进行训练和验证。表8展示了所提出的深度学习模型在番茄病害检测训练与测试阶段的最终结果。研究发现，DenseNet121模型在训练集（99.88%）和测试集（99.00%）准确率方面均取得最高成绩。其召回率、准确率和F1值均高于平均水平，分别达到99.00%、99.00%和98.99%。ResNet50V2模型的训练准确率为99.49%，测试准确率为95.60%，均低于前代模型。其召回率、准确率和F1值均逊于DenseNet121，分别为95.60%、94.80%和95.59%。ViT模型在训练和测试中的准确率均为98.00%，召回率为98.00%，精确度为98.00%，F1值为98.00%。研究结果表明，DenseNet121在番茄病害识别方面表现最佳，其次是ViT，最后是ResNet50V2。DenseNet121的ROC曲线图如图13所示。

表8.深度学习在训练和测试阶段的总结结果。

90%训练数据和10%测试数据集的模型性能					
模型名称	训练准确率%	测试准确率%	回忆率	精密度%	F1 Score%
致密网121	99.88		99	99	99
ResNet50V2	99.49		95.60	95.60	95.8
维生素T	98		98	98	98

80%训练集和20%测试集数据集的模型性能					
模型名称	训练准确率%	测试准确率%	回忆率	精密度%	F1 Score%
致密网121	99.99		98.45	98.45	94.32
ResNet50V2	99.99		94.43	94.31	98.46
维生素T	99.27		94.90	94.90	94.97




图13.ROC曲线DenseNet121模型。

此外，研究还对比了推荐模型与其他多个模型的预测难度差异。在准确率分析章节中，详细展示了文献数据集中番茄叶部病害的预测成果。实验数据显示，采用非推荐方法的研究中，我们提出的DenseNet121模型以99.88%的准确率表现最佳，相关数据详见表9和图14。

表9.DenseNet121与不同CNN模型结果的比较。

参考文献	模型	数据集	准确度%
裁判员[62]	植入v3	同一数据集	96.60
裁判员[63]	ResNet-50		98.77
裁判员[64]	移动网络		88.4
裁判员[65]	VGG16		93.5
裁判员[66]	中心体		98.2
裁判员[67]	ResNet50 + SeNet		96.81
提议系统	DenseNet121模型		99.64




图14.DenseNet121与不同CNN模型在准确度方面的结果比较。

6. 结论

本研究旨在分析并应用多种深度学习模型，用于番茄植株病害诊断任务。我们选择Kaggle平台公开数据集，因其包含可能影响番茄叶片的十种病害信息。基于该数据集，我们提出了三种新型卷积神经网络架构用于番茄病害预测与分类，并结合专用深度学习架构DenseNet121、ResNet50V2及ViT模型进行研究。

深度学习已成为检测植物（包括番茄）病害的有力工具。通过神经网络分析大量植物图像数据集，深度学习模型可学会识别特定病害的特征模式与特征。这项技术能帮助农民和研究人员快速精准地诊断植物病害，从而制定更精准的防治方案。研究结果显示，DenseNet121、ResNet50V2和ViT等深度学习模型在番茄病害检测中表现优异。其中DenseNet121在训练集上的准确率高达99.88%，测试集准确率也达到99%，表现最为突出。ResNet50V2和ViT模型虽然准确率同样较高，但性能稍逊于DenseNet121。这些发现表明，深度学习模型能为番茄病害检测提供高效精准的解决方案，最终将惠及整个农业产业。分析结果表明，所推荐模型的性能优于其他替代方案。该研究提出的番茄病害识别方法具有创新性，但其局限性在于系统尚未整合到移动应用程序中。然而，该方法仅需用户拍摄受病植株叶片的图像，即可实现番茄叶片病害的简易低成本诊断。未来，我们计划借助物联网（IoT）技术支持的更先进人工智能技术来优化该模型。

补充材料： 以下支持信息可从以下网址下载：<https://www.mdpi.com/article/10.3390/agronomy13051184/s1>，图S1：DenseNet121模型的性能；(a) DenseNet121模型的准确率，(b) DenseNet121模型的损失（80%训练和20%测试）；图S2：DenseNet121的混淆矩阵（80%训练和20%测试）；图S3：性能

关于ResNet50V2模型: (a) ResNet50V2模型的准确率与(b) ResNet50V21模式损失(80%训练集与20%测试集); 图S4: ResNet50V2模型的混淆矩阵(80%训练集与20%测试集); 图S5: ViT模型性能: (a) ViT模型准确率与(b) ViT模式损失(80%训练集与20%测试集); 图S6: ViT模型的混淆矩阵(80%训练集与20%测试集); 表S1: DenseNet121模型在(80%训练集与20%测试集)中的结果; 表S2: ResNet50V2模型在(80%训练集与20%测试集)中的结果; 表S3: ViT模型在(80%训练集与20%测试集)中的结果。

作者贡献: 概念设计由M.S.A.和F.W.A.共同完成; 方法学设计由M.S.A.和F.W.A.共同完成; 软件开发由M.S.A.和F.W.A.共同完成; 验证工作由M.S.A.和F.W.A.共同完成; 正式分析由M.S.A.和F.W.A.共同完成; 调查研究由M.S.A.和F.W.A.共同完成; 资源调配由M.S.A.和F.W.A.共同完成; 数据管理由M.S.A.和F.W.A.共同完成; 初稿撰写由M.S.A.和F.W.A.共同完成; 审阅与编辑由M.S.A.和F.W.A.共同完成; 可视化呈现由M.S.A.和F.W.A.共同完成; 项目理由M.S.A.和F.W.A.共同完成。资金获取、M.S.A.和F.W.A.。所有作者均已阅读并同意发表的文稿版本。

资金来源: 作者们感谢沙特阿拉伯教育部研究与创新副部通过项目编号INST048为本研究工作提供资金支持。

数据可用性声明: <https://www.kaggle.com/datasets/kaustubhb999/tomatoleaf> (2023年1月20日访问)。

利益冲突: 作者声明无利益冲突。

参考文献

1. Schreinemachers, P.; Simmons, E.B.和Wopereis, M.C.挖掘蔬菜的经济和营养潜力。《全球粮食安全》2018, 16, 36-45。[交叉引用]
2. Stilwell, M. 2018年全球番茄在线新闻处理。在线获取: <https://www.tomatonews.com/> (2023年2月15日访问)。
3. 王, R.; 拉默斯, M.; 蒂库诺夫, Y.; 博维, A.G.; 安格内特, G.C.; 德马格德, R.A. rin、nor和Cnr自发突变以加性与上位性方式抑制番茄果实成熟。《植物科学》2020, 294, 110436–110447。[交叉引用] [PubMed]
4. Ahmad, A.; Saraswat, D.; El Gamal, A.关于使用深度学习技术进行植物病害诊断的调查及开发适当工具的建议。《智能农业技术》2023, 3, 100083。[交叉引用]
5. 余宇、萨马利·B、拉希迪·M、穆罕默迪·M、阮廷宁、张刚. 基于视觉的混凝土裂缝检测——考虑噪声效应的混合框架。《建筑工程学报》2022, 61, 105246。[交叉引用]
6. Sahin, M.E.; Uluta,s, H.; Yuce, E. 一种用于胸部X线片中肺炎检测的深度学习算法。《欧洲科学技术杂志》2021, 28, 562–567。[交叉引用]
7. Bock, C.H.; Parker, P.E.; Cook, A.Z.; Gottwald, T.R.目测评级和图像分析在评估葡萄柚叶柑橘溃疡病不同症状中的应用。《植物病害》2008, 92, 530-541。[交叉引用]
8. 余宇; 梁思; 萨马利·B; 阮廷南; 翟超; 李杰; 谢晓基于改进鸟群算法优化的二维卷积神经网络评估钢筋混凝土梁的扭转承载力。《工程结构》2022, 273, 115066。[交叉引用]
9. 斯潘蒂亚德斯, S.T.; 吉安诺普洛斯, A.E.; 卡普萨利斯, N.C.; 卡普萨利斯, C.N.一种利用多个磁偶极子对航天器设备的磁信号进行建模的深度学习算法。《IEEE磁学快报》2021, 12, 1–5。[交叉引用]
10. 朴, H.; 尹, J.S.; 金, S.H. 基于图像的作物疾病诊断与预测的深度学习机制。在2017年10月18日至20日于韩国济州岛举行的2017年国际信息与通信技术融合会议(ICTC)论文集; 第129-131页。
11. 萨尔多甘, M.; 通切尔, A.; 奥岑, Y. 基于CNN和LVQ算法的植物叶片病害检测与分类。在2018年9月20日至23日于波斯尼亚和黑塞哥维那萨拉热窝举行的第三届国际计算机科学与工程会议(UBMK)论文集; 第382-385页。
12. Singh, V.; Misra, A.K. 基于图像分割与软计算技术的植物叶片病害检测 《信息过程与农业》2017年第4卷第41–49页。[交叉引用]
13. 张, S.; 吴, X.; 余, Z.; 张, L.基于叶片图像的稀疏表示分类黄瓜病害识别。《计算电子农业》2017, 134, 135–141。[交叉引用]
14. Ferentinos, K.P. 深度学习模型在植物病害检测与诊断中的应用。《计算电子农业》2018, 145, 311–318。[CrossRef]
15. 德瓦拉杰, A.; 拉坦, K.; 贾纳维, S.; 因迪拉, K. 使用图像处理技术识别植物病害。在2019年4月4日至6日印度金奈举行的2019年国际通信与信号处理会议(ICCSP)论文集; 第749-753页。

16. 穆吉特, P.K.; 穆杜努里, R.V.; 拉贾塞卡尔, B.; 卡蒂凯扬, S. 植物病害自动检测及农场警报系统的图像处理技术。载于《2020年国际通信与信号处理会议 (ICCSP) 论文集》, 印度金奈, 2020年7月28-30日; 第1603-1607页。
17. Phadikar, S.; Sil, J. 基于模式识别技术的水稻病害识别。载于《2008年第11届国际计算机与信息技术会议论文集》, 孟加拉国库尔纳, 2008年12月24-27日; 第420-423页。
18. Sarayloo, Z.; Asemani, D. 基于模式识别技术设计小麦植株真菌病害自动检测分类器。载于《2015年第23届伊朗电气工程会议论文集》, 伊朗德黑兰, 2015年5月10-14日; 第1193-1197页。
19. Thangadurai, K.; Padmavathi, K. 计算机视觉图像增强技术在植物叶片病害检测中的应用。载于《2014年世界计算与通信技术大会论文集》, 印度特里奇拉帕利, 2014年2月27日至3月1日; 第173-175页。
20. 永, Z.; 同辉, R.; 昌明, L.; Chao, W.; Jiya, T. 基于计算机视觉的玉米常见病害识别方法研究。2019年8月24-25日, 中国杭州, 第11届国际智能人机系统与控制会议 (IHMSC) 论文集, 第1卷, 第328-331页。
21. Khirade, S.D.; Patil, A.B. 基于图像处理的植物病害检测。载于《2015年国际计算通信控制与自动化会议论文集》, 印度浦那, 2015年2月26-27日; 第768-771页。
22. Kamilaris, A.; Prenafeta-Boldi, F.X. 农业中的深度学习: 综述. *Comput. Electron. Agric.* **2018**, *147*, 70-90. [交叉引用]
23. 李, L.; 张, S.; 王, B. 基于深度学习的植物病害检测与分类——综述. *IEEE Access* **2021**, *9*, 56683-56698. [交叉引用]
24. 李, S.H.; 陈, C.S.; 威尔金, P.; 雷马尼诺, P. 深度植物: 使用卷积神经网络进行植物识别。2015年9月27日至30日, 加拿大魁北克市, IEEE国际图像处理会议 (ICIP) 论文集, 第452-456页。
25. 张宇、宋超、张德基于深度学习的番茄病害目标检测改进. *IEEE Access* **2020**, *8*, 56607-56614. [交叉引用]
26. Sabrol, H.; Satish, K. 数字图像中番茄植物病害分类树。在国际通信与信号处理会议 (ICCSP) 论文集, 印度梅尔马鲁瓦图尔, 2016年4月6日至8日; 第1242-1246页。
27. 哈桑, M.; 塔纳瓦拉, B.; 帕特尔, K.J. 深度学习精准农业: 通过迁移学习检测番茄叶病。在第二届国际先进计算与软件工程会议 (ICACSE) 论文集, 苏丹普尔, 印度, 2019年2月8-9日。
28. Adhikari, S.; Shrestha, B.; Baiju, B.; Kumar, S. 使用图像处理的番茄植物病害检测系统。在第1届 KEC 工程与技术会议论文集, Lalitpur, Nepal, 2018年9月27日; 第1卷, 第81-86页。
29. Salih, T. A. 深度学习卷积神经网络检测和分类番茄植株叶片病害. *Open Access Libr. J.* **2020**, *7*, 12. [交叉引用]
30. Ishak, S.; Rahiman, M.H.; Kanafiah, S.N.; Saad, H. 基于人工神经网络的叶片病害分类. 《技术杂志》 **2015**, *77*, 109-114. [交叉引用]
31. Sabrol, H.; Kumar, S. 基于模糊和神经网络的番茄植物病害分类, 使用自然室外图像. *印度科技杂志* **2016**, *9*, 1-8. [交叉引用]
32. Rangarajan, A.K.; Purushothaman, R.; Ramesh, A. 基于预训练深度学习算法的番茄作物病害分类. *Procedia Comput. Sci.* **2018**, *133*, 1040-1047. [交叉引用]
33. Coulibaly, S.; Kamsu-Foguem, B.; Kamissoko, D.; Traore, D. 基于迁移学习的深度神经网络在小米作物图像中的应用. 《计算工业》, *2019*, *108*, 115-120. [交叉引用]
34. Sangeetha, R.; Rani, M. 基于迁移学习的番茄叶病预测。载于《2020年国际先进计算会议论文集》, 印度帕纳吉, 2020年12月5-6日。
35. Mortazi, A.; Bagci, U. 自动设计用于医学图像分割的CNN架构。载于《医学影像机器学习国际研讨会论文集》, 西班牙格拉纳达, 2018年9月16日; 第98-106页。
36. 江, D.; 李, F.; 杨, Y.; 余, S. 基于深度学习的番茄叶病分类方法。中国控制与决策会议 (CCDC) 论文集, 中国合肥, 2020年8月22-24日; 第1446-1450页。
37. Rashid, J.; Khan, I.; Ali, G.; Almotiri, S.H.; AlGhamdi, M. A.; Masood, K. 多层次深度学习模型用于马铃薯叶片疾病识别. *电子学* **2021**, *10*, 2064. [交叉引用]
38. 植物村。在线获取: <https://www.kaggle.com/emmarex/plantdisease> (2023年2月3日访问)。
39. 拉克什曼拉奥, A.; 巴布, M.R.; 基兰, T.S.R. 深度学习卷积神经网络在植物病害预测和分类中的应用。在2021年9月24日至26日于印度甘地讷格尔举行的2021年国际人工智能与机器视觉会议 (AIMV) 论文集; 第1-6页。
40. S.V. Militante; B.D. Gerardo; N.V. Dionisio 深度学习在植物叶片检测与病害识别中的应用载于2019年10月3日至6日台湾云林举行的2019年IEEE欧亚 IOT、通信和工程会议 (ECICE) 论文集, 第579-582页。

41. 马祖吉, F.; 埃卢赫, M.; 克赫拉拉, M. 深度卷积神经网络方法用于植物病害检测。在2020年11月28日至30日于埃及吉萨举行的第21届国际阿拉伯信息技术会议 (ACIT) 论文集; 第1-6页。
42. Ngugi, L.C.; Abdelwahab, M.; Abo-Zahhad, M. 基于深度学习的手机应用番茄叶片分割算法. *计算电子农业* **2020**, *178*, 105788.[交叉引用]
43. 罗扎基, A.J.; 苏尼托, A. 基于卷积神经网络 (CNN) 算法的马铃薯叶片病害识别。载于《2020年第三届国际信息与通信技术会议 (icoiact) 论文集》, 印度尼西亚日惹, 2020年11月24-25日; 第72-76页。
44. 马蒂哈尔, C.; 格德法耶, E.; 恩达拉马, F.; 内乔, A. 农业土地的实时自动化, 通过自动检测植物叶片疾病和自动用药。2018年5月16日至18日, 波兰克拉科夫, 第32届国际先进信息网络与应用研讨会 (WAINA) 论文集, 第325-330页。
45. 迪维亚什里, P.; 平托, L. A.; 玛丽, L.; 马纳萨, P.; 达斯, S. 基于CNN模型的实时移动应用用于咖啡叶片疾病识别。在2021年第二届国际电子与可持续通信系统会议 (ICESC) 论文集, 印度科因巴托尔, 2021年8月4-6日; 第1694-1700页。
46. 刘, J.; 王, X. 基于MobileNetV2-YOLOv3模型的番茄灰叶斑病早期识别. *植物方法* **2020**, *16*, 83. [交叉引用] [PubMed]
47. Khasawneh, N.; Faouri, E.; Fraiwan, M. 基于深度迁移学习的番茄病害自动检测. *应用科学* **2022**, *12*, 8467.[交叉引用]
48. Mim, T.T.; Sheikh, M.H.; Shampa, R. A.; Reza, M.S.; Islam, M.S. 基于图像处理技术的番茄叶片病害检测。载于《2019年第八届国际系统建模与研究趋势进展会议 (SMART) 论文集》, 印度莫拉达巴德, 2019年11月22-23日; 第244-249页。
49. 库马尔, A.; 瓦尼, M. 基于图像的番茄叶片病害检测。载于2019年7月6日至8日在印度坎普尔举行的第10届国际计算、通信和网络技术会议 (ICCCNT) 论文集, 第1-6页。
50. Tm, P.; Pranathi, A.; SaiAshritha, K.; Chittaragi, N.B.; Koolagudi, S.G. 基于卷积神经网络的番茄叶病检测。载于《2018年第十一届国际当代计算会议 (IC3) 论文集》, 印度诺伊达, 2018年8月2-4日; 第1-5页。
51. 康, F.; 李, J.; 王, C.; 王, F. 一种基于神经网络的马铃薯早疫病和晚疫病叶片识别方法. *应用科学* **2023**, *13*, 1487. [交叉引用]
52. Al-Gaashani, M.S.A.M.; Shang, F.; Muthanna, M.S.A.; Khayyat, M.; El-Latif, A.A.A. 利用迁移学习和特征拼接对番茄叶病进行分类. *IET ImageProcess.* **2022**, *16*, 913-925.[交叉引用]
53. 帕坦, S.M.K.; 阿里, M.F. 快速卷积神经网络在水稻病害识别系统中的实现载于2019年12月26日至28日在孟加拉国拉杰沙希举行的第三届国际电气、计算机和电信工程会议 (ICECTE) 论文集, 第189-192页。
54. 周, G.; 张, W.; 陈, A.; 何, M.; 马, X. 基于 FCM -KM和Faster R-CNN融合的水稻病害快速检测. *IEEE Access* **2019**, *7*, 143190-143206. [交叉引用]
55. Cardellicchio, A.; Solimani, F.; Dimauro, G.; Petrozza, A.; Summerer, S.; Cellini, F.; Rena, V. 基于YOLOv5的单阶段检测器检测番茄植株表型性状. *Comput. Electron. Agric.* **2023**, *207*, 107757.[交叉引用]
56. 刘, G.; 努阿兹, J.C.; 图科·姆布姆贝, P.L.; 金, J.H. YOLO-Tomato: 基于YOLOv3的番茄检测鲁棒算法. *Sensors* **2020**, *20*, 2145. [交叉引用]
57. 刘杰、王曦. 基于改进Yolo V3卷积神经网络的番茄病虫害检测. *植物科学前沿* **2020**, *11*, 898.[交叉引用]
58. 阿尔德哈尼, T.H.H.; 奈尔, R.; 阿尔扎因, E.; 阿尔卡赫塔尼, H.; 孔达尔, D. 基于改进的基于扩张方法的实时乳腺癌图像检测的深度神经网络模型. *诊断学* **2022**, *12*, 2505. [交叉引用]
59. 阿尔德哈尼, T.H.; 阿尔谢巴米, A.S.A.; 阿尔扎赫拉尼, M.Y. 《软计算模型在慢性病预测中的应用》. 《信息科学与工程杂志》 **2020**, *36*, 365-376。
60. Al-Adhaileh, M.H.; Aldhyani, T.H.H. 用于建模和预测作物产量以增强沙特阿拉伯粮食安全的人工智能框架. *PeerJ Comput. Sci.* **2022**, 2022, e1104.[交叉引用] [PubMed]
61. Al-Adhaileh, M.H.; Verma, A.; Aldhyani, T.H.H.; Koundal, D. 基于微调CNN架构的马铃薯晚疫病检测. 《数学》 **2023**, *11*, 1516.[交叉引用]
62. Widyyanto, S.; Fitrianto, R.; Wardani, D.T. 应用卷积神经网络方法对番茄叶片疾病进行分类。在2019年第四届国际信息学与计算会议 (ICIC) 论文集, 印度尼西亚三宝壟, 2019年10月16-17日; 第1-5页。
63. 马蒙, M.A.A.; 卡里姆, D.Z.; 平库, S.N.; 布什拉, T.A. TLNet: 一种用于预测番茄叶病的深度CNN模型。2020年12月19日至21日, 孟加拉国达卡, 第23届国际计算机与信息技术会议 (ICCIT) 论文集; 第1-6页。
64. 艾哈苏尼, A.; 斯马兰达切, F. 智能移动应用程序利用卷积神经网络识别番茄叶病。2019年7月22日至24日, 摩洛哥阿加迪尔, 国际计算机科学与可再生能源会议 (ICCSRE) 论文集, 第1-4页。
65. 阿加瓦尔, M.; 古普塔, S.K.; 比斯瓦斯, K.K. 番茄作物病害识别高效CNN模型的开发. *可持续计算与信息系统* **2020**, *28*, 100407. [交叉引用]

66. Lamba, M.; Gigras, Y.; Dhull, A.利用机器和深度学习对植物病害进行分类.*Open Comput. Sci.***2021**, *11*, 491–508.[\[交叉引用\]](#)
67. 赵, S.; 彭, Y.; 刘, J.; 吴, S. 基于注意力模块改进卷积神经网络的番茄叶病诊断. *农业* **2021**, *11*, 651. [\[交叉引用\]](#)

免责声明/出版商注：所有出版物中的陈述、观点和数据仅代表作者及贡献者个人，与 MDPI 及编辑无关。MDPI 及编辑不承担因内容中提及的任何观点、方法、指导或产品导致的人身伤害或财产损失的责任。